Домашнее задание 3

Зыков Макар Романович

Вариант 11 - DevOps инженер

Репозиторий проекта на GitHub

Расчеты выполнены на CPU в Google Colab, RustFS для этих расчетов развернут в той же облачной среде, оба метода читают один объект S3. Локальный стенд RustFS с EC 2+2 ранее был развернут в Д32 на macOS

Исходный набор, **229 388 записей**, отобрано **6 503 DevOps-вакансий**. Полные таблицы частот собственного MapReduce и DuckDB совпали во всех проверенных запусках. Зарплатная выборка, 1 108 вакансий, медиана 200 000 руб. на руки

Результат	Подтверждение
Объектное хранилище	RustFS 1.0.1, hh-lake, GET и SHA-256 совпадают
Два независимых расчета	Python MapReduce и SQL DuckDB, навыки, пары, тройки
Эксперименты	Стек 5, 10, 30, минимум 3 попытки, время и RSS
Надежность	Принудительное завершение mapper, повтор без двойного счета
Анализ	Зарплаты, положительные и отрицательные различия, 3 региона
Сдача	Исходники, SQL, CSV результатов, замеры и PDF-отчет

Расчеты относятся к предоставленному набору вакансий 2024 года. Различия медиан описывают связь с набором навыков и не доказывают влияние конкретного навыка на зарплату

Данные и правила отбора

Фильтр, точное значение role = «DevOps-инженер» ИЛИ отдельное обозначение DevOps / Dev Ops / Dev-Ops / девопс в названии вакансии без учета регистра. SRE, MLOps и DevSecOps попадают в основной анализ только при соответствующей профессии DevOps-инженер

Проверка	Результат
Всего строк	229 388
DevOps	6 503
Уникальные vacancy_id	6 503
Повторные ID в выборке	0
Пустой список навыков	2 051
Указана зарплата в любой валюте	1 539
Сопоставимая зарплата RUR, gross=false	1 108

Навыки, разбиение key_skills по «;», удаление краевых пробелов, перевод в нижний регистр, удаление повторов внутри вакансии, лексикографическая сортировка. Синонимы не объединяются. Пара и тройка не зависят от порядка. Каждая вакансия дает единицу частоты каждому своему сочетанию

Допущение о размерах стека. Присланное ТЗ требует три размера, но не задает их значения. Взяты первые 5, 10 и 30 навыков после нормализации и сортировки. Это эксперимент с ограничением стека, не размер чанка. Стек 30 охватывает фактический максимум, проверенный в данных. Для выводов о зарплате и регионах используется полный стек. Алфавитное усечение не является рейтингом важности навыков

Размер чанка MapReduce - 1000 отобранных вакансий, одновременно до двух задач и два mapper-процесса. Исходный CSV разбирается потоковым CSV-парсером, а не разбиением по байтовым границам

RustFS и контроль исходного объекта

В Д32 на macOS локально запускался RustFS 1.0.1 с четырьмя каталогами хранения на одном физическом томе APFS и схемой EC 2+2, в бакет it-vacancies был загружен исходный CSV и проверен через S3 GET и SHA-256. Скриншоты локального стенда из Д32 приведены в приложении и относятся именно к этому запуску. Для вычислений Д33 отдельно создан одноузловой RustFS в Google Colab с одним каталогом хранения на облачной VM и бакетом hh-lake. Этот облачный стенд не воспроизводит эксперимент по отказоустойчивости Д32. Доступ к S3 API внутри VM осуществлялся по адресу 127.0.0.1:19000, публичный туннель не создавался. Секрет генерировался при запуске и не включен в материалы сдачи

Параметр	Значение
Объект	s3://hh-lake/raw/it_vacancies_2024.csv
Размер, байт	847 619 384
HEAD	847 619 384 байт
Полный GET	Контрольная сумма совпала
Версия	RustFS 1.0.1, Linux x86_64

CSV сначала загружен с компьютера в файловую систему Colab, распакован и записан через S3 multipart upload. Далее расчетные программы получают данные через S3, Python - get_object и поток, DuckDB - read_csv по s3://. Локальный CSV не используется как источник вычислений

Команды воспроизведения, python src/pipeline.py upload, python src/pipeline.py profile, python src/pipeline.py benchmark, python src/pipeline.py analysis, python src/pipeline.py publish. Исходники и SQL входят в структуру проекта

После публикации результатов HEAD проверен для 90 объектов. Полный перечень, results/s3_objects.json

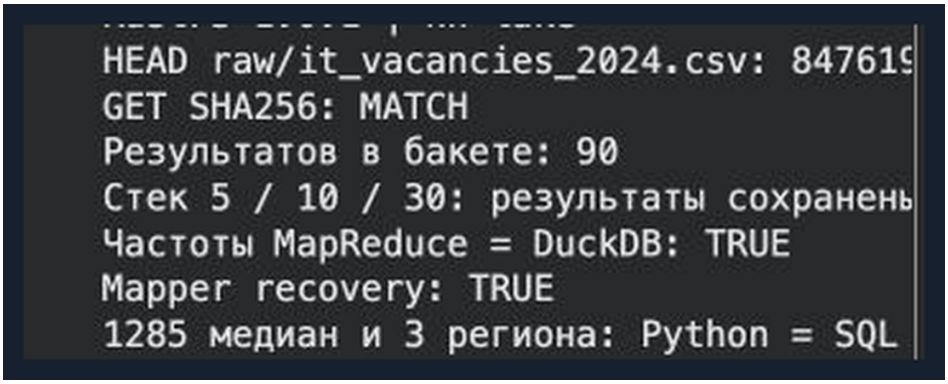
Хранилище Colab временное, содержимое бакета доступно только пока существует облачная VM. Для долговременного хранения используется отдельное постоянное хранилище или повторная загрузка данных

Подтверждение загрузки данных

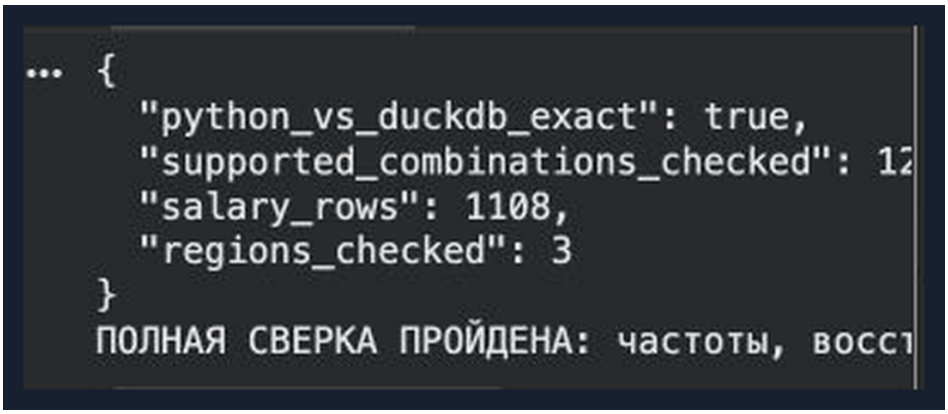
Исходный CSV загружен в RustFS внутри Google Colab через S3 multipart upload. Ниже представлены контрольные параметры исходного объекта и вывод проверки по S3 API. Скриншоты локального RustFS из Д32 приведены в приложении

Бакет Д33	hh-lake
Объект S3	raw/it_vacancies_2024.csv
Размер по HEAD	847 619 384 байта
Проверка GET и SHA-256	Контрольная сумма совпала
Исходных вакансий	229 388
Отобрано по варианту DevOps	6 503
Сохраненных результатов в бакете	90 объектов, проверены через HEAD

Фрагмент сохраненного вывода проверки S3 из Google Colab



Фрагмент выполненной независимой проверки результатов



Полные машиночитаемые результаты проверок сохранены в results/storage.json, results/verification.json и results/s3_objects.json. Изображения выше показывают только видимую часть сохраненного вывода Colab

Частоты навыков и сочетаний

Стек	Длина сочетания	Различных ключей	Всего вхождений
5	1	984	20 605
5	2	5 602	39 013
5	3	10 030	37 498
10	1	1 378	31 317
10	2	14 615	110 000
10	3	59 872	247 273
30	1	1 661	36 415
30	2	25 987	177 876
30	3	192 009	697 421

Для вакансии с k навыками получаем C(k, 1)=k одиночных навыков, C(k, 2)=k(k-1)/2 пар, C(k, 3)=k(k-1)(k-2)/6 троек. При k=5 это 5, 10 и 10, при k=10 - 10, 45 и 120, при k=30 - 30, 435 и 4060. Различных ключей меньше суммарных вхождений, поскольку одни сочетания встречаются в нескольких вакансиях



Независимая проверка и отказ mapper

Python реализует mapper с itertools.combinations и собственный reducer с Counter. DuckDB независимо выполняет SQL-фильтрацию, нормализацию списков и соединение навыков по vacancy_id с условиями a<b<c. DuckDB не читает промежуточные счетчики MapReduce

Стек	Проверенных таблиц	Сравненных ключей	Расхождения
5	6	16 616	0
10	6	75 865	0
30	9	219 657	0

Сравниваются полные словари (длина сочетания, навыки) → частота, включая отсутствие лишних ключей. Дополнительно число отобранных вакансий во всех запусках сравнивается с профилем данных. Результаты одинаковы между повторами и между исходной и оптимизированной реализациями

Для проверки отказа один mapper принудительно завершается os._exit(23) на последнем неполном чанке. ProcessPoolExecutor сообщает BrokenProcessPool. Координатор создает новый пул и повторяет незавершенную группу задач. Группа коммитится только после успешного завершения всех ее задач, идентификаторы чанков предотвращают повторное применение

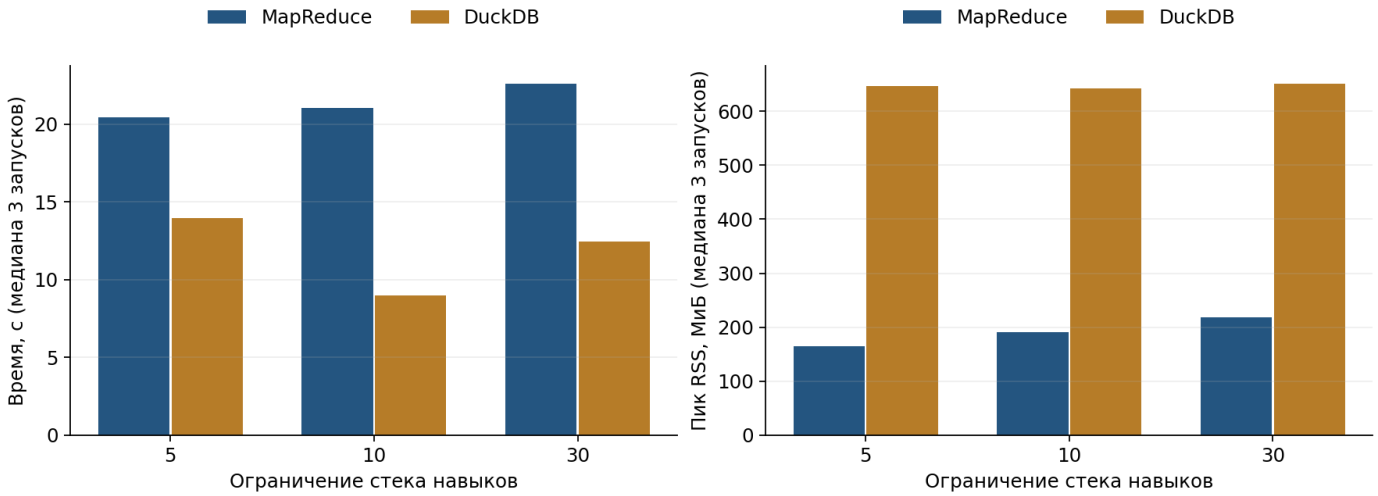
Контроль	Результат
Отказ mapper обнаружен	True
Повторенных групп	1
Успешных чанков	7
Полное совпадение после повтора	True
Время с восстановлением, с	22.582

Это проверка отказа процесса на одной VM, а не отказа распределенного кластера. Память состояния reducer не восстанавливается после потери координатора, такой сценарий в эксперимент не входит

Сравнение времени и памяти

Каждый замер запускается в новом Python-процессе. Для каждого размера стека выполнено по три запуска MapReduce и DuckDB, порядок чередуется. Настройка расширения httpfs выполнена заранее. CSV полностью читается из RustFS при каждом запуске, кэш ОС не очищается, это повторные, а не гарантированно холодные чтения

Способ	Стек	Попытки	Медиана, с	Медиана пика, МиБ
duckdb	5	3	13.962	646.4
duckdb	10	3	9.005	643.0
duckdb	30	3	12.457	651.7
mapreduce	5	3	20.439	165.3
mapreduce	10	3	21.032	190.5
mapreduce	30	3	22.612	218.2
mapreduce_optimized	30	3	22.421	216.8



Время wall включает запуск процесса, чтение S3, вычисление и сохранение CSV. Отдельное compute_seconds включает подготовку клиента/соединения и чтение, но исключает запись итогового CSV. RSS измерен с интервалом 20 мс, сумма RSS координатора и его дочерних mapper. RustFS и ноутбук не включены. RSS может повторно учитывать общие страницы между процессами, это не уникальная физическая память. Очень короткие пики между отсчетами могли быть пропущены

Интерпретация производительности и оптимизация

Для полного стека отношение медиан времени MapReduce / DuckDB равно 1.82. Это результат именно этой VM, объема CSV и параметров двух рабочих процессов/потоков, универсальное преимущество одного подхода из одного опыта не следует

Базовый mapper материализует список всех сочетаний чанка и затем строит счетчик. Оптимизированный mapper сразу обновляет Counter из генератора сочетаний. Входной S3-объект, фильтр, размер чанка, число процессов и выходные частоты одинаковы

Показатель	База	Оптимизация
Медиана времени, с	22.612	22.421
Медиана пика RSS, МиБ	218.2	216.8
Число попыток	3	3
Совпадение частот	Полное	Полное

Изменение относительно базы, время +0.8% экономии, RSS +0.6% экономии. Отрицательное значение означает ухудшение. Вывод об улучшении делается отдельно по каждой метрике, три повтора не дают строгой оценки статистической значимости небольших различий

Для малых стеков чтение большого CSV и разбор строк могут составлять значительную долю времени. Рост числа сочетаний увеличивает вычисления и объем словарей, но время не обязано расти пропорционально C(k, 3), одновременно действуют I/O, кэш и накладные расходы процессов

Метод сравнения зарплат

Зарплатная выборка, currency=RUR и gross=false. Если обе границы заполнены, используется их среднее, если одна - эта граница. Значения без зарплаты, неположительные и перевернутые диапазоны исключаются. Среднее границ является приближением, а не фактической выплатой. Валюты не пересчитываются, НДФЛ не моделируется

В сопоставимой выборке 1 108 вакансий из 6 503 (17.0%). Медиана 200 000 руб. на руки. Выводы относятся к вакансиям с раскрытой сопоставимой зарплатой, пропуски не заменены нулями

Для пары A+B базой служит навык с большей частотой во всех DevOps-вакансиях. Для тройки A+B+C - наиболее частая содержащаяся пара. При равных частотах выбирается лексикографически первая база. Сравнение включает вакансии базы с дополнительным навыком и без него, поэтому это вложенные выборки

Δ = медиана сочетания − медиана базы, Δ% = 100 × Δ / медиана базы. В итоговый рейтинг включены сочетания и базы минимум с 20 зарплатными наблюдениями. Порог выбран до рейтинга, это ограничение поддержки, а не тест статистической значимости. В полном CSV сохранены квартильные границы и все прошедшие порог сочетания

Опыт	Вакансий с зарплатой	Медиана, руб
От 3 до 6 лет	532	250 000
От 1 года до 3 лет	443	150 000
Более 6 лет	74	300 000
Нет опыта	59	60 000

Опыт, регион, работодатель и уровень должности могут объяснять различия. Отрицательная разница не означает, что навык сам по себе снижает оплату, возможны различия состава вакансий. Рейтинг исследовательский, многие сочетания проверяются одновременно, причинная модель не строилась

Более высокая медиана у пар навыков

Сочетание / база	n / n базы	Медиана / база, руб	Δ, руб	Δ, %
devops + terraform База, devops	47 / 315	300 000 / 200 000	100 000	50.0
python + terraform База, python	24 / 205	270 000 / 200 000	70 000	35.0
terraform + zabbix База, zabbix	26 / 187	270 000 / 200 000	70 000	35.0
gitlab ci + postgresql База, postgresql	24 / 293	287 500 / 215 000	72 500	33.7
ansible + gitlab ci База, ansible	27 / 285	275 000 / 215 000	60 000	27.9
bash + elk База, bash	35 / 226	275 000 / 215 000	60 000	27.9

Наибольшая показанная разница, devops + terraform. Медиана 300 000 руб. против 200 000 руб. у базы «devops», Δ 50.0%, n=47. Это наблюдаемая связь в выбранной подвыборке

Возможное объяснение - сочетание навыков характерно для другого уровня опыта или другого типа работодателей. Для проверки причин потребовалось бы сопоставление вакансий по этим признакам. Данные этого расчета не позволяют приписать разницу только дополнительному навыку

Более низкая медиана у пар навыков

Сочетание / база	n / n базы	Медиана / база, руб	Δ, руб	Δ, %
bash + sql База, bash	29 / 226	100 000 / 215 000	-115 000	-53.5
debian + nginx База, nginx	21 / 238	100 000 / 200 000	-100 000	-50.0
linux + tcp/ip База, linux	27 / 552	100 000 / 200 000	-100 000	-50.0
debian + linux База, linux	27 / 552	120 000 / 200 000	-80 000	-40.0
bash + mysql База, bash	24 / 226	150 000 / 215 000	-65 000	-30.2
postgresql + субд База, postgresql	21 / 293	150 000 / 215 000	-65 000	-30.2

Наибольшая показанная разница, bash + sql. Медиана 100 000 руб. против 215 000 руб. у базы «bash», Δ -53.5%, n=29. Это наблюдаемая связь в выбранной подвыборке

Возможное объяснение - сочетание навыков характерно для другого уровня опыта или другого типа работодателей. Для проверки причин потребовалось бы сопоставление вакансий по этим признакам. Данные этого расчета не позволяют приписать разницу только дополнительному навыку

Более высокая медиана у троек навыков

Сочетание / база	n / n базы	Медиана / база, руб	Δ, руб	Δ, %
bash + devops + elk База, bash + devops	25 / 102	350 000 / 217 500	132 500	60.9
bash + elk + nginx База, bash + nginx	20 / 86	262 500 / 175 000	87 500	50.0
devops + linux + terraform База, devops + linux	33 / 221	300 000 / 200 000	100 000	50.0
kubernetes + terraform + zabbix База, kubernetes + zabbix	21 / 119	300 000 / 210 000	90 000	42.9
git + linux + terraform База, git + linux	22 / 169	262 500 / 185 000	77 500	41.9
devops + docker + terraform База, devops + docker	40 / 213	282 500 / 200 000	82 500	41.2

Наибольшая показанная разница, bash + devops + elk. Медиана 350 000 руб. против 217 500 руб. у базы «bash + devops», Δ 60.9%, n=25. Это наблюдаемая связь в выбранной подвыборке

Возможное объяснение - сочетание навыков характерно для другого уровня опыта или другого типа работодателей. Для проверки причин потребовалось бы сопоставление вакансий по этим признакам. Данные этого расчета не позволяют приписать разницу только дополнительному навыку

Более низкая медиана у троек навыков

Сочетание / база	n / n базы	Медиана / база, руб	Δ, руб	Δ, %
bash + linux + sql База, bash + linux	26 / 174	100 000 / 220 000	-120 000	-54.5
linux + nginx + sql База, linux + nginx	22 / 164	125 000 / 200 000	-75 000	-37.5
ansible + bash + zabbix База, ansible + bash	28 / 104	160 000 / 250 000	-90 000	-36.0
bash + postgresql + zabbix База, bash + postgresql	24 / 90	142 500 / 220 000	-77 500	-35.2
git + grafana + prometheus База, grafana + prometheus	33 / 122	150 000 / 227 500	-77 500	-34.1
ci/cd + git + grafana База, ci/cd + grafana	23 / 79	135 000 / 200 000	-65 000	-32.5

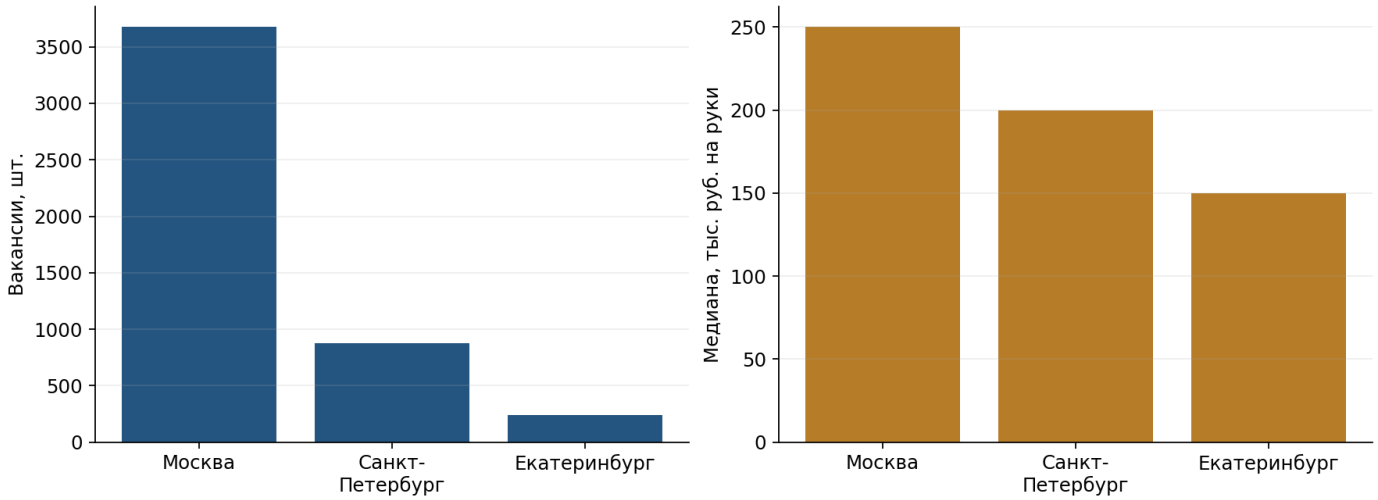
Наибольшая показанная разница, bash + linux + sql. Медиана 100 000 руб. против 220 000 руб. у базы «bash + linux», Δ -54.5%, n=26. Это наблюдаемая связь в выбранной подвыборке

Возможное объяснение - сочетание навыков характерно для другого уровня опыта или другого типа работодателей. Для проверки причин потребовалось бы сопоставление вакансий по этим признакам. Данные этого расчета не позволяют приписать разницу только дополнительному навыку

Три региона и сопоставимые зарплаты

Выбраны Москва, Санкт-Петербург и Екатеринбург, три крупных региона основной выборки. Регион - поле area, а не фактическое место проживания сотрудника, удаленная вакансия может относиться к офису работодателя. Количество вакансий и доли навыков считаются по всем выбранным вакансиям региона, зарплаты - по сопоставимой подвыборке

Регион	Всего	С навыками	n зарплат	Покрытие, %	Медиана, руб
Москва	3 676	2 469	560	15.2	250 000
Санкт-Петербург	876	613	167	19.1	200 000
Екатеринбург	240	165	44	18.3	150 000



Москва лидирует по числу DevOps-вакансий, 3 676 из 6 503, и имеет наиболее высокую медиану среди сопоставимых объявлений, 250 000 руб. В Санкт-Петербурге медиана равна 200 000 рублей, в Екатеринбурге - 150 000 рублей. Это различия опубликованных зарплат, а не оценка фактических доходов всех специалистов

Доля вакансий с сопоставимой зарплатой составляет 15,2% в Москве, 19,1% в Санкт-Петербурге и 18,3% в Екатеринбурге. Поэтому медианы нельзя без оговорок переносить на все объявления. Доли навыков рассчитаны от общего числа вакансий каждого региона, включая объявления без key_skills

Навыки пары и тройки по регионам

Москва

k	Навыки	Частота	Доля, %	n зарплат	Медиана, руб
1	linux	1 520	41.3	259	220 000
1	kubernetes	1 341	36.5	211	275 000
2	docker + kubernetes	876	23.8	158	270 000
2	docker + linux	839	22.8	164	230 000
3	docker + kubernetes + linux	565	15.4	101	260 000
3	devops + docker + kubernetes	388	10.6	76	287 500

Санкт-Петербург

k	Навыки	Частота	Доля, %	n зарплат	Медиана, руб
1	linux	397	45.3	86	210 000
1	docker	344	39.3	85	200 000
2	docker + linux	228	26.0	55	220 000
2	docker + kubernetes	199	22.7	45	220 000
3	docker + kubernetes + linux	127	14.5	30	240 000
3	ansible + docker + linux	118	13.5	31	250 000

Екатеринбург

k	Навыки	Частота	Доля, %	n зарплат	Медиана, руб
1	linux	113	47.1	28	160 000
1	docker	94	39.2	24	172 500
2	docker + kubernetes	72	30.0	20	175 000
2	kubernetes + linux	72	30.0	22	170 000
3	docker + kubernetes + linux	54	22.5	14	175 000
3	ansible + kubernetes + linux	41	17.1	14	170 000

Полная региональная таблица включает топ-10 навыков, пар и троек для каждого из трех регионов, всего 90 строк, файл results/regions_skills_pairs_triples.csv. Для одинаковой тройки docker + kubernetes + linux доля вакансий в Екатеринбурге выше, чем в Москве, 22,5% против 15,4%, но медиана зарплаты по объявлениям с этой тройкой ниже, 175 000 против 260 000 руб. Число сопоставимых зарплат для этой тройки, 14 и 101 соответственно. Это показывает, что частота стека не определяет зарплату сама по себе. При небольших подвыборках выводы требуют осторожности, причинная связь не устанавливалась

Воспроизводимость и ограничения

Ноутбук и исходники сохраняют настройки, SQL и журналы. results/benchmark_runs.csv содержит каждый замер, benchmark_summary.csv - медианы. verification.json фиксирует полную сверку, mapper_failure.json - восстановление, salary_all_supported.csv - все поддержанные зарплатные сочетания. Частоты каждого запуска сохранены отдельно и выгружены в S3

Основные ограничения, размеры стека 5, 10 и 30 и состав региональных таблиц выбраны для данного эксперимента, инфраструктура состоит из одного облачного узла, чтения повторяются с кэшем ОС, зарплатный анализ охватывает только вакансии с раскрытой сопоставимой зарплатой, значения зарплаты приближенно рассчитаны по границам, причинная интерпретация и проверка статистической значимости не проводились

Источники и документация

Предоставленное ТЗ и критерии оценивания, Список вариантов.xlsx, строка Зыков Макар Романович

Отчет Д32 с подтверждениями локального RustFS, CSV it_vacancies_2024.csv с SHA-256, приведенным выше

RustFS 1.0.1, https://github.com/rustfs/rustfs/releases/tag/1.0.1

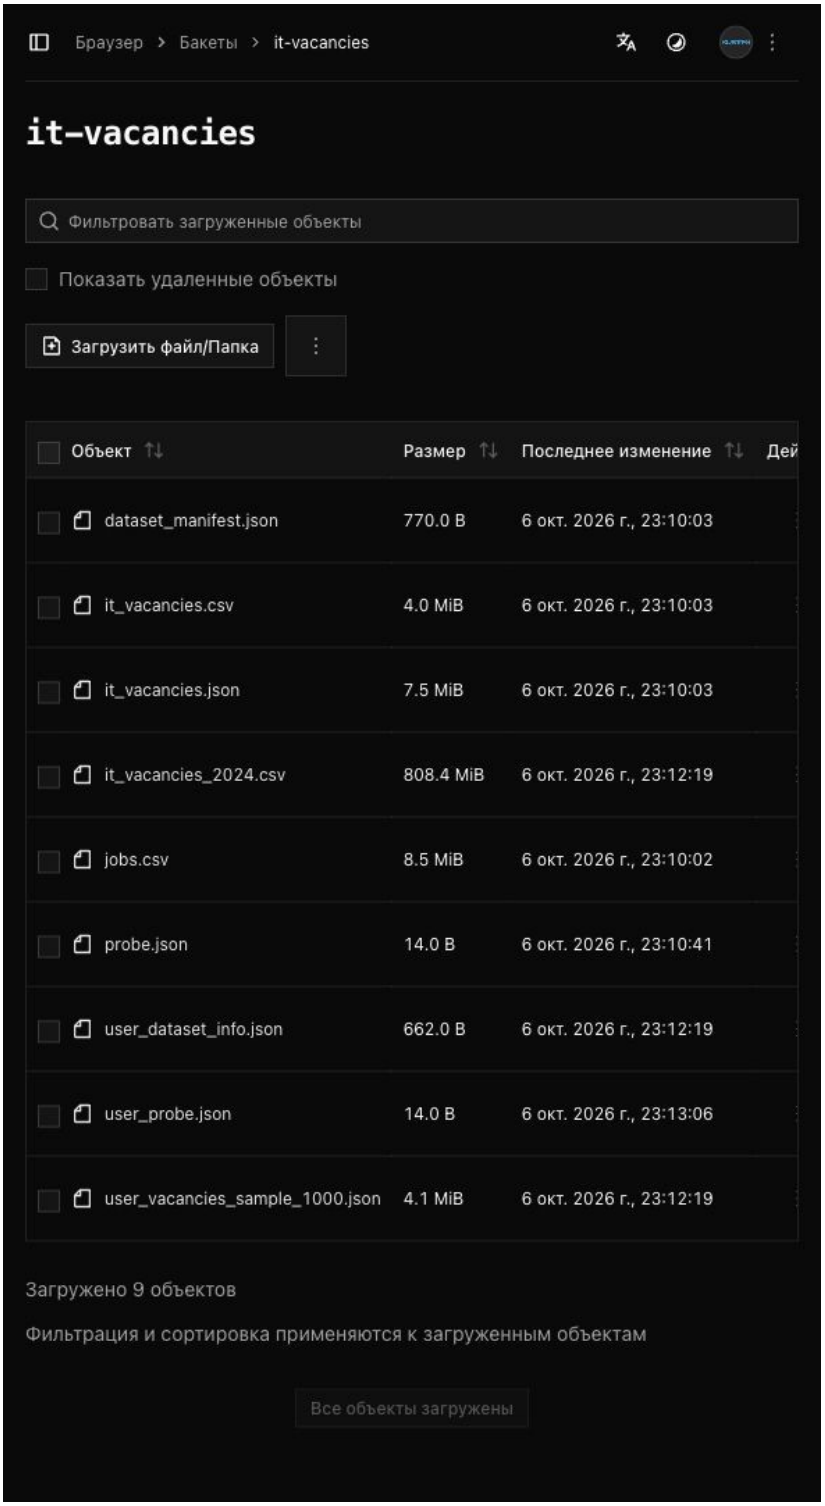
DuckDB S3 API, https://duckdb.org/docs/stable/core_extensions/httpfs/s3api.html

Ноутбук, https://colab.research.google.com/drive/18tdEHgEzH16MMqmATXIIaPR1WHNHIrQy

Приложение - локальный RustFS из Д32

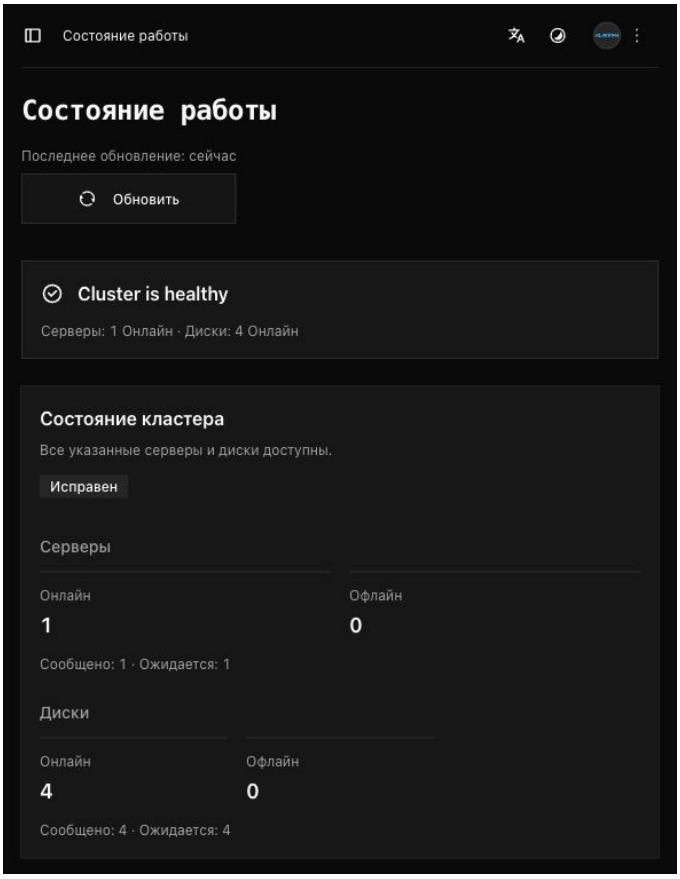
Скриншоты ниже взяты из отчета Д32 и подтверждают ранее выполненное локальное развертывание на macOS. Они не являются скриншотами стенда Д33 в Colab

Локальный бакет it-vacancies и загруженный исходный CSV it_vacancies_2024.csv



Локальное хранилище, состояние и EC 2+2

Четыре доступных каталога хранения на локальном стенде Д32 после восстановления



Конфигурация RustFS из Д32, тип Erasure и стандартная четность 2

